

Clasificación multilabel de intención de crédito

De un baseline con LASER a una comparación justa entre LaBSE, TF-IDF y BERT

Miguel Angel Liera Montaña | Entrevista técnica, Data Scientist Sr

El problema: ¿para qué quiere el crédito?

- Cada solicitud declara en texto libre el uso del crédito: puede tener varios propósitos a la vez.
- Textos cortos en español, con ruido (typos, mayúsculas, caracteres especiales).
- Valor: estructurar la intención para riesgo, producto y analítica.
- Referencia interna: Binary Relevance + regresión logística sobre LASER.

10

etiquetas (multilabel)

≈ 1.15

etiquetas por texto

$\approx 12\times$

desbalance: Inventory
vs Seasonal

≈ 15

palabras por texto

Metodología (CRISP-DM)

1

Limpieza

Datos nulos,
duplicados exactos y
normalizados.

2

Partición

80/10/10,
estratificada por
número de
etiquetas.

3

Modelos

- LaBSE + LR
- TF-IDF + LR
- BERT
fine-tune.

4

Umbrales

Por etiqueta,
maximizando F1 en
validación.


5

Evaluación


Test una sola vez: 6
métricas, por
etiqueta.

Exploración de Datos y Limpieza

Registros por clase (desbalance)



Longitud del texto (palabras, recortado a 60)



Co-ocurrencia de etiquetas

crec -	0	7	39	0	52	12	0	33	19	
cred -	7	0	31	3	36	10	3	10	4	
equ -	39	31	0	6	170	52	0	131	43	
inic -	0	3	6	0	13	3	0	13	2	
inv -	52	36	170	13	0	48	1	122	42	
mkt -	12	10	52	3	48	0	0	35	22	
no -	0	3	0	0	1	0	0	0	0	
renta -	33	10	131	13	122	35	0	0	35	
sueldo -	19	4	43	2	42	22	0	35	0	
temp -									0	
	crec -	cred -	equ -	inic -	inv -	mkt -	no -	renta -	sueldo -	temp -

- Distribución de clases
- Distribución normal sobre la longitud del texto
- Co-ocurrencia

Limpieza

	motivos	crec	cred	equ	inic	inv	mkt	no	renta	suelo	temp
628	CAPITAL DE TRABAJO COMPRA DE MATERIA Y MANO DE...	0	0	0	1	0	0	0	1	0	NaN
710	Para incrementar ventas tener inventarios	0	0	0	1	0	0	0	0	0	NaN
1130	Capital de trabajo\n,0,0,0,0,0,0,0,1,0,0\nRe i...	0	0	0	0	0	0	0	0	0	NaN
1437	Tengo que hacer renovación de Consepción	0	0	0	0	0	1	0	0	0	NaN
1699	PARA LA COMPRA DE ACTIVOS FIJOS PARA LA EMPRESA	0	0	0	1	0	0	0	0	0	NaN
2263	Compra de equipos de cómputo para lanzar proye...	0	1	0	0	0	0	0	0	0	NaN

- Valores nulos
- Un duplicado más que un outlier es un error.
- normalización + estrategia de recuperación de valores repetidos

	text	labels
0	Ampliar mi negocio y comprar mas mercancia	crec,inv
1	Ampliar mi negocio. Y comprar mas mercancia	inv
2	CAPITAL DE TRABAJO, GASTOS DE OPERACION Y COMP...	equ,inv
3	Capital de trabajo, gastos de operación y comp...	equ
4	CAPITAL DE TRABAJO, GASTOS DE OPERACIÓN Y COMP...	equ,inv
5	Capital de trabajo, para crecimiento de la emp...	inv
6	Capital de trabajo para crecimiento de la empresa	crec
7	LO UTILIZAREMOS PARA CAPITAL DE TRABAJO E INOV...	crec
8	lo utilizaremos para capital de trabajo e inov...	inv
9	lo utilizaremos para capital de trabajo e inov...	equ,renta
10	LOS RECURSOS SE EMPLEARAN EN LA COMPRA DE MATE...	equ
11	LOS RECURSOS SE EMPLEARAN EN LA COMPRA DE MATE...	equ,inv

Tres enfoques, un mismo procedimiento

LaBSE + LR

- Embeddings multilingües congelado.
- Binary Relevance: una regresión logística por etiqueta.
- C elegido en validación.

Réplica del baseline

TF-IDF + LR

- 300 términos, unigramas y bigramas.
- Misma regresión logística por etiqueta.
- Sin GPU, latencia mínima.


Baseline léxico, el más barato

BERT fine-tune

- bert-base-multilingual-uncased, cabeza multilabel.
- BCEWithLogits con pos_weight (neg/pos).
- Padding dinámico, lr 2e-5, 2 épocas.




Finetune

Entrenamiento



Resultados finales en test


- LaBSE + LR tiene el mejor Hamming




Resultados finales en test

- BERT lidera en F1
- Diferencias de 0.01 a 0.02 no son concluyentes con una sola partición.
- TradeOff entre intenciones minoritarias y costo.

Comparación de desempeño general F1



Average Precision por clase (test)



Lectura crítica: qué se sostiene y qué no

Lo que se sostiene

- Los umbrales por etiqueta dan el mayor salto de Macro F1.
- BERT lidera en F1 en test, sobre todo por las clases minoritarias.
- Los tres modelos se eligieron con el mismo criterio: validación.
- Test se usó una sola vez para reportar.

Cautelas

- temp y sueldo tienen pocos positivos: umbrales y F1 ruidosos.
- BERT conserva pos_weight sin ablación.

Despliegue: medir antes de complicar

1 Medir

- Latencia y memoria en el hardware objetivo
- Calibración de probabilidades por etiqueta

2 Modo sombra

- TF-IDF y BERT en paralelo sin afectar decisiones
- Comparar con una muestra etiquetada

3 Decidir

- Modelo único si BERT cumple la latencia

Siempre umbrales versionados con el modelo, monitoreo de drift y de F1 por etiqueta (temp, sueldo), y revisión humana en casos ambiguos

Limitaciones y próximos pasos

Limitaciones

- Conjunto de prueba pequeño
- *temp* y *suelto*: pocos positivos, umbrales ruidosos
- Etiquetas ruidosas y duplicados contradictorios

Próximos pasos

- Intervalos bootstrap y tabla por etiqueta con soporte
- Calibración y análisis de errores en *temp* y *suelto*
- Medir latencia, memoria y calibración antes de elegir la arquitectura